

Projeto de controladores não lineares utilizando referência virtual

Dissertação de mestrado

Tassiano Neuhaus
Orientador: Alexandre Sanfelice Bazanella

PPGEE - UFRGS

Setembro de 2012

Agenda

- 1 Objetivo e Motivação
- 2 Introdução
 - Identificação de sistemas
 - Propriedades estatísticas das estimativas
 - Sinais utilizados
- 3 Classes de Modelos
 - Classes de modelos lineares
 - Classes de modelos não lineares
 - Algoritmo de identificação de sistemas racionais
- 4 Projeto de controladores baseados em dados
 - Referência Virtual
- 5 Projeto de controladores não lineares utilizando referência virtual
 - Sistema do tipo Wiener
 - Sistemas Racionais
- 6 Conclusões

Objetivo / Motivação

Objetivo

Apresentar um estudo sobre projeto de controladores não lineares utilizando identificação de sistemas e o conceito de referência virtual.

Motivação

- Controladores não lineares são pouco explorados
- Para alguns tipos de sistemas, controladores não lineares conseguem ser mais performáticos

Definições

Foco em sistemas SISO

Sistemas *Single input single output* (SISO) discretos:

$$y(t) = G_0(z)u(t) + H_0(z)e(t)$$

onde $G_0(z)$ é a representação da planta real do sistema, H_0 é a representação do filtro que atua sobre o ruído $e(t)$. $y(t)$ é a saída e $u(t)$ é a entrada do sistema.

Definições

Identificação de sistemas

Identificação de sistemas pode ser dividido em 3 partes principais:

- O sistema real a ser identificado \mathcal{S}

$$\mathcal{S} : y(t) = G_0(z)u(t) + H_0(z)e(t) \quad (1)$$

- A classe de modelos a ser utilizada na identificação \mathcal{M}

$$\mathcal{M} : \{G(z, \theta), H(z, \theta) | \theta \in D_{\mathcal{M}}\} \quad (2)$$

Definições

Identificação de sistemas

- Algum critério para elencar qual modelo dentro da classe de modelos melhor consegue representar o sistema \mathcal{S} nas propriedades escolhidas.

Neste trabalho optou-se por:

$$V(\theta) = \frac{1}{N} \sum_{t=1}^N \frac{1}{2} \varepsilon^2(t, \theta) \quad (3)$$

onde $\varepsilon(t, \theta)$ é o erro de predição e pode ser definido como:

$$\varepsilon(t, \theta) = H^{-1}(z, \theta) \{y(t) - G(z, \theta)u(t)\}$$

Definições

Propriedades estatísticas das estimativas

- θ : Representa a estimativa obtida com um experimento.
- θ_0 : conjunto de parametros que faz com que:

$$G(z, \theta_0) \equiv G_0(z)$$

- $\hat{\theta}_N$: Estimativa para um certo valor de N pontos.
- θ^* : Valor de convergência da estimativa quando $N \rightarrow \infty$:

$$\lim_{N \rightarrow \infty} \hat{\theta}_N = \theta^*$$

Definições

Propriedades estatísticas das estimativas - Erros envolvidos

Erros atrelados às estimativas

$$\text{Erro de variância} = G(z, \hat{\theta}_N) - G(z, \theta^*)$$

$$\text{Erro de polarização} = G(z, \theta^*) - G_0(z)$$

Onde observa-se que o erro de polarização é a diferença entre o valor real $G_0(z)$ e a melhor aproximação possível (quando $N \rightarrow \infty$) $G(z, \theta^*)$.

Erro de variância é a diferença entre cada uma das estimativas obtidas e a estimativa quando $N \rightarrow \infty$ $G(z, \theta^*)$

Definições

Propriedades estatísticas das estimativas - Elipse de confiança

Região de confiança é definido pela elipse:

$$U_{\theta} = \left\{ \theta \mid (\hat{\theta}_N - \theta_0)^T P_N^{-1} (\hat{\theta}_N - \theta_0) \leq \chi_{\alpha}^2(n) \right\}$$

onde:

$$P(\theta^*) \triangleq \lim_{N \rightarrow \infty} N E(\hat{\theta}_N - \theta^*)(\hat{\theta}_N - \theta^*)^T$$




Figura: Estimativas de um sistema e a elipse representando a região de confiança para um χ de 99%.

Definições

Sinal PRBS

Sinal PRBS

$$u(t) = \text{rem}(A(z)u(t), 2) = \text{rem}(a_1 u(t-1) + \dots + a_n u(t-n), 2)$$

Ordem n	$M = 2^n - 1$	a_k não zeros para k
2	3	1, 2
3	7	2, 3
4	15	1, 4
5	31	2, 5
6	63	1, 6
7	127	3, 7
8	255	1, 2, 7, 8
9	511	4, 9
10	1023	7, 10
11	2047	9, 11




Figura: Sinal PRBS para $n = 7$

Classes de modelos

Sistemas lineares - SISO de tempo discreto

Classe de modelos genérica

$$A(z)y(t) = \frac{B(z)}{F(z)}u(t) + \frac{C(z)}{D(z)}e(t)$$

onde:

$$A(z, \theta) = 1 + a_1 z^{-1} + \dots + a_{na} z^{-n_a}$$

$$B(z, \theta) = b_1 z^{-1} + \dots + b_{nb} z^{-n_b}$$

$$C(z, \theta) = 1 + c_1 z^{-1} + \dots + c_{nc} z^{-n_c}$$

$$D(z, \theta) = 1 + d_1 z^{-1} + \dots + d_{nd} z^{-n_d}$$

$$F(z, \theta) = 1 + f_1 z^{-1} + \dots + f_{nf} z^{-n_f}$$

Polinômios $\neq 1$	Nome
B	FIR
AB	ARX
ABC	ARMAX
AC	ARMA
ABD	ARARX
ABCD	ARARMAX
BF	OE
BFGD	Box-Jenkins

Classes de modelos

Sistemas não lineares

- Muitos são os tipos de classes de modelos para sistemas não lineares.
- Eles podem ser divididos em dois tipos principais:
 - Não linearidades estáticas
 - Não linearidades dinâmicas
- Diversas classes de modelos se diferenciam pela escolha da base que irá representar o sistema.

Classes de modelos

Sistemas não lineares

- **Volterra:** Relaciona valores passados da entrada com o valor atual da saída.

$$y(t) = \sum_{j=1}^{\infty} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} h_j(\tau_1, \dots, \tau_j) \prod_{i=1}^j u(t - \tau_i) d\tau_i$$

- **Redes Neurais:**

$$x = f \left(\sum_{j=1}^n \omega_j x_j + b \right)$$

- Redes neurais multi camadas
 - Redes neurais recorrente
- **Funções radiais de base:** Casos particulares de redes neurais, mas lineares nos parâmetros ω_i .

$$f(y) = \omega_0 + \sum_i \omega_i \phi(\|y - c_i\|)$$

Classes de modelos - NARMAX

Sistemas não lineares

Nonlinear AutoRegressive Moving Average model with eXogenous variables

$$y(t) = \theta^T \Phi_{nl}(y, u, e)$$

onde $\Phi_{nl}(\cdot)$ denota um campo vetorial que depende dos valores passados de $y(t)$ e presente e passados de $u(t)$ e $e(t)$; θ é o vetor de parâmetros a ser identificado.

Classes de modelos - NARMAX

Modelo Polinômial

Modelo polinômial

$$y(t) = \sum_{m=0}^l \sum_{p=0}^m \sum_{n_1, n_m}^{n_y, n_u} c_{p, m-p}(n_1, \dots, n_m) \prod_{i=1}^p y(t - n_i) \prod_{i=p+1}^m u(t - n_i)$$

sendo que

$$\sum_{n_1, n_m}^{n_y, n_u} \equiv \sum_{n_1=1}^{n_y} \cdots \sum_{n_m=1}^{n_y}$$

Exemplo:

$$y(t) = \alpha_1 u^2(t-1) + \alpha_2 y(t-1)y^2(t-2) + \alpha_3 u(t-2)y(t-1)$$

Classes de modelos - NARMAX

Modelo Racional

Modelo Racional

$$y(t) = \frac{a(y(t-1), \dots, y(t-n_y), u(t-1), \dots, u(t-n_u), \dots}{b(y(t-1), \dots, y(t-n_y), u(t-1), \dots, u(t-n_u), \dots} \dots \frac{e(t-1), \dots, e(t-n_e))}{e(t-1), \dots, e(t-n_e))} + e(t)$$

$$a(t-1) = \sum_{j=1}^{N_n} p_{nj} \theta_{nj} = \psi_n^T(t-1) \theta_n$$

$$b(t-1) = \sum_{j=1}^{N_d} p_{dj} \theta_{dj} = \psi_d^T(t-1) \theta_d$$

Exemplo:

$$y(t) = \frac{\alpha_1 u^2(t-1) + \alpha_2 y(t-1) y^2(t-2) + \alpha_3 u(t-2) y(t-1)}{1 + \alpha_4 u^3(t-1) y(t-2) + \alpha_5 y^3(t-1)}$$

Algoritmo para identificação de modelos racionais

Pode ser utilizado para modelos polinômiais

Modelo

$$y(t) = \frac{a(y(t-1), \dots, y(t-n_y), u(t-1), \dots, u(t-n_u))}{b(y(t-1), \dots, y(t-n_y), u(t-1), \dots, u(t-n_u))} + c(e(t-1), \dots, e(t-n_e)) + e(t)$$

- O ruído é modelado por um polinômio que pode ou não ser linear.

Algoritmo para identificação de modelos racionais

Passo 1

Faça $i = 0$. Monte a matriz Ψ de regressão e estime os parâmetros usando o método dos mínimos quadrados:

$$\begin{bmatrix} \hat{\theta}_n^i \\ \hat{\theta}_{d1}^i \end{bmatrix} = [\Psi^T \Psi]^{-1} \Psi^T y^*$$

$$\Psi = \begin{bmatrix} \psi_n^T(t-1) & \psi_{d1}^T(t-1) \\ \vdots & \vdots \\ \psi_n^T(t+N-2) & \psi_{d1}^T(t+N-2) \end{bmatrix}$$

Algoritmo para identificação de modelos racionais

Passo 2

Faça $i = i + 1$. Determine os resíduos e sua variância, respectivamente como:

$$\xi^i(t) = y(t) - \frac{\psi_n^T(t-1)\hat{\theta}_n}{\psi_d^T(t-1)\hat{\theta}_d}$$

$$(\sigma_\xi^2)^i = \frac{1}{N - m_d} \sum_{i=m_d+1}^N (\xi^i(t))^2$$

Passo 3

Usando-se os resíduos determinados no passo anterior, atualize $\Psi^T \Psi$ e $\Psi^T y^*$ usando:

$$\Psi = \begin{bmatrix} \psi_n^T(t-1) & y(t)\psi_{d1}^T(t-1) & \psi_\xi^T(t-1) \\ \vdots & \vdots & \vdots \\ \psi_n^T(t+N-2) & y(t)\psi_{d1}^T(t+N-2) & \psi_\xi^T(t+N-2) \end{bmatrix}$$

Algoritmo para identificação de modelos racionais

Passo 4 e 5

Passo 4: Determine:

$$\Phi = \begin{bmatrix} 0 & \dots & 0 & 0 & \dots & 0 & \dots & 0 & \dots & 0 \\ \vdots & & \vdots & \vdots & & \vdots & & \vdots & & \vdots \\ 0 & \dots & 0 & \sum_{t=1}^N p_{d2}^2 & \dots & \sum_{t=1}^N p_{d2} p_{dN_d} & \dots & 0 & \dots & 0 \\ \vdots & & \vdots & \vdots & & \vdots & & \vdots & & \vdots \\ 0 & \dots & 0 & \sum_{t=1}^N p_{dN_d} p_{d2} & \dots & \sum_{t=1}^N p_{dN_d}^2 & \dots & 0 & \dots & 0 \end{bmatrix}$$

$$\phi = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ -\sum_{k=1}^N p_{d2} p_{d1} \\ \vdots \\ -\sum_{k=1}^N p_{dN_d} p_{d1} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

E estime novamente os parâmetros utilizando:

$$\begin{bmatrix} \hat{\theta}_n^i \\ \hat{\theta}_{d1}^i \end{bmatrix} = \left[\Psi^T \Psi - (\sigma_\xi^2)^i \Phi \right]^{-1} \left[\Psi^T y^* - (\sigma_\xi^2)^i \phi \right]$$

Passo 5: Volte ao Passo 2 até atingir convergência (de parâmetro ou de variância de resíduo).

Projeto de controladores baseados em dados

Definições

Sistema básico de controle




Figura: Representação de um sistema de controle em malha fechada, com ruído aditivo na saída.

$$T(z, \theta) = \frac{C(z, \theta)G_0(z)}{1 + C(z, \theta)G_0(z)}$$

Projeto de controladores baseados em dados

Critérios de performance

- Seguimento de referência,
- Rejeição ao ruído e
- Uso reduzido de esforço de controle.

Para o objetivo de **seguimento de referência**, a performance pode ser avaliada pela norma:

$$J_y(\theta) \triangleq \bar{E} [y(t) - y_d(t)]^2 = \bar{E} [(T(z, \theta) - T_d(z))r(t)]^2$$


Controlador ideal - Seguimento de referência

$$C_d(z) = \frac{T_d(z)}{G_0(z)(1 - T_d(z))}$$

Referência Virtual para identificação de controladores

Método VRFT

- Método VRFT utiliza referência virtual para obtenção dos sinais necessários à identificação.



- O método VRFT faz com que a função custo a ser minimizada seja quadrática em θ , não recaindo em mínimos locais.

$$J_{VR}^N(\theta) = \frac{1}{N} \sum_{t=1}^N (u_L(t) - \varphi_L^T(t)\theta)^2$$

$$\varphi_L(t) = \beta(z)\epsilon_L(t)$$

Método VRFT - função custo de um sistem hipotético





Figura: O valor θ^* é o ponto de mínimo de ambas as funções custo, logo, minimizando a função custo $J_{VR}(\theta)$ é o equivalente a minimizar $J_Y(\theta)$ sob condições ideais.

Projeto de controladores não lineares baseados em dados

União do algoritmo de identificação de sistemas não lineares com referência virtual

Definições

- Deseja-se que o sistema não linear, se comporte linearmente em malha fechada: $T_d(z)$
- C_d é quem proporciona isso.



Projeto de controladores não lineares baseados em dados

União do algoritmo de identificação de sistemas não lineares com referência virtual

Objetivo para encontrar o controlador

$$\min_{\theta} J^{VR}(\theta)$$

$$J^{VR}(\theta) \triangleq \frac{1}{N} \sum_{t=1}^N \left[(u(t) - C(\bar{\psi}_C(t), \theta))^2 \right].$$

Classes de modelos exploradas:

- Não linearidades estáticas: Sistema do tipo Wiener
- Não linearidades dinâmicas: Sistema racional (NARMAX)


Projeto de controladores não lineares baseados em dados

Sistema do tipo Wiener - Não linearidade estática na saída

Wiener

$$z(t) = G_0(z)u(t) + H_0(z)e(t)$$


$$y(t) = \phi(z(t))$$



Controlador: Hammerstein

$$u(t) = C'_d(z)v(t)$$

$$v(t) = r(t) - \psi(y(t))$$



Observação

Fica claro que mesmo no caso padrão o controlador ideal não é uma função do erro $r(t) - y(t)$, mas sim de $r(t)$ e $y(t)$ separadamente.

Projeto de controladores não lineares baseados em dados

Sistema do tipo Wiener - Não linearidade estática na saída

Assumindo que a referência $r(t)$ seja constante, uma topologia alternativa é tornar o controlador dependente do erro de referência.

Controlador dependente do erro de referência

$$\begin{aligned} u(t) &= C'(z, \theta)v(t) \\ v(t) &= \psi(r(t) - y(t), \eta) \end{aligned}$$

onde

$$\psi(r(t) - y(t)) = \alpha[r(t) - z(t)]$$




Figura: Diagrama de blocos de um sistema não linear do tipo Wiener.

Sistema do tipo Wiener

Exemplo numérico

Sistema Real

$$G_0(z) = \frac{0.5}{z - 0.9}$$

$$\phi(z(t)) = y(t) = 1.5z(t) + 0.2z^3(t)$$

Comportamento desejado

$$M(z) = \frac{0.4}{z - 0.6}$$

Classe de controlador (PI):

$$C(z, \theta) = \theta_1 \frac{1}{z - 1} + \theta_2 \frac{z}{z - 1}$$

e

$$\psi(\epsilon(t)) = a_1\epsilon(t) + a_2\epsilon^2(t) + a_3\epsilon^3(t) + a_4\epsilon^4(t)$$

Sistema do tipo Wiener

Exemplo numérico

Parte linear do controlador

$$C_d'(z) = \frac{0.8z - 0.72}{z - 1} \quad (4)$$

Classe do controlador

$$u_f(t) = \theta_1 \epsilon(t) + \theta_2 \epsilon^2(t) + \theta_3 \epsilon^3(t) + \theta_4 \epsilon^4(t) + \theta_6 \epsilon^2(t-1) + \theta_7 \epsilon^3(t-1) + \theta_8 \epsilon^4(t-1) \quad (5)$$

100 Monte Carlo experimentos foram realizados e a média das estimativas obtidas foi:

$$\theta_{\text{média}} = \begin{bmatrix} 0.44717 \\ 2.0216 \times 10^{-3} \\ -6.5181 \times 10^{-4} \\ -1.608 \times 10^{-5} \\ -0.40435 \\ -1.6163 \times 10^{-3} \\ 6.1265 \times 10^{-4} \\ 1.469 \times 10^{-5} \end{bmatrix}$$

O custo obtido foi: $J^{MR}(\theta_{\text{média}}) = 3.0078 \times 10^{-3}$;

Sistema do tipo Wiener

Exemplo numérico




Figura: relação entre os sinais $v(t)$ e $z(t)$ quando o sistema é alimentado por um degrau unitário

Projeto de controladores não lineares baseados em dados

Sistema Racionais - Não linearidade na dinâmica do sistema

Sistemas racionais

Projeto de controladores não lineares baseados em dados

Sistema Racionais - Não linearidade na dinâmica do sistema

Quando a planta é um sistema racional e o comportamento em malha fechada é linear, o controlador ótimo pode ser também representado por um modelo racional.

Exemplificando:

Sistema real

$$y(t) = \frac{0.5u(t-1)y(t-1) + u(t-1)}{1 + 0.25y^2(t-2)}$$

Comportamento em malha fechada esperado:

$$T_d(z) = \frac{0.4}{z - 0.6}$$

$$y(t) = 0.4r(t-1) + 0.6y(t-1)$$

Controlador ótimo para este conjunto

$$u(t) = \frac{0.4r(t) + 0.6y(t) + 0.1y^2(t-1)r(t) + 0.15y(t)y^2(t-1)}{1 + 0.5y(t)}$$

Sistema Racionais - Não linearidade na dinâmica do sistema

Exemplo numérico: $\mathcal{C}_d \in \mathcal{C}$


Classe de modelos do controlador: $\mathcal{C}_d \in \mathcal{C}$

$$u(t) = \frac{\theta_1 r(t) + \theta_2 y(t) + \theta_3 y^2(t-1)r(t) + \theta_4 y(t)y^2(t-1)}{1 + \theta_5 y(t)}$$


Utilizando um sinal PRBS de 254 pontos (ordem 7) e fazendo 100 experimentos de Monte Carlo com um ruído de variância de $\sigma_e^2 = 0.005$

$\theta_{\text{média}} = [0.4000 \quad 0.5999 \quad 0.1001 \quad 0.1501 \quad 0.5000]$

Custo obtido foi $J_y(\theta_{\text{médio}}) = 0.0033$ e
 $J_{VR}(\theta_{\text{médio}}) = 2.7291 \times 10^{-8}$



Erro entre a resposta esperada e a obtida:



Sistema Racionais - Não linearidade na dinâmica do sistema

Exemplo numérico: $\mathcal{C}_d \notin \mathcal{C}$

Considerando o mesmo sistema real apresentado anteriormente:

Classe de modelos do controlador: $\mathcal{C}_d \notin \mathcal{C}$

$$u(t) = \frac{\theta_1 r(t) + \theta_2 y(t) + \theta_3 r(t)y(t-1) + \theta_4 y(t-1)y(t)}{1 + \theta_5 y(t)}$$

Utilizando um sinal PRBS de 254 pontos (ordem 7) e fazendo 100 experimentos de Monte Carlo com um ruído de variância de $\sigma_e^2 = 0.005$

$$\theta_{\text{média}} = [0.4696 \quad 0.7011 \quad 0.0083 \quad 0.0063 \quad 0.5013]$$

Custo obtido foi $J_y(\theta_{\text{médio}}) = 1.0999$

Sistema Racionais - Não linearidade na dinâmica do sistema

Exemplo numérico: $C_d \notin \mathcal{C}$




Figura: Exemplo onde $C_d \notin \mathcal{C}$: Resposta do sistema ao degrau unitário para o sistema desejado $T_d(z)$ e o sistema quando o controlador parametrizado por $\theta_{\text{médio}}$

Conclusões

- Utilização de algoritmos de identificação de sistemas não lineares pode ser estendida para a identificação de controladores não lineares.
- Referência virtual traz diversas vantagens para a obtenção dos dados para alimentação dos algoritmos não lineares.
- Resultados obtidos com os exemplos apresentados podem ser considerados satisfatórios para um grande número de aplicações.

Questões

Muito Obrigado.